

RELATÓRIO TÉCNICO

Análise e Normalização Etiológica dos Dados de SRAG / SIVEP-Gripe

Documentação das decisões metodológicas, implementação, testes e integração do pipeline epidemiológico

Projeto: SRAG Epidemiological Data Platform

Repositório: GT09PetSaudeDigital/grupo-srag — módulo guilherme

Período analisado: 2019–2026

Data da consolidação: 17 de agosto de 2026

1. Resumo executivo

Objetivo. Revisar e corrigir a forma como o pipeline SRAG representava a classificação final do caso e a etiologia identificada em exames laboratoriais, eliminando a mistura conceitual entre essas duas dimensões e preparando a base para análises epidemiológicas e futuras etapas de Machine Learning.

Resultado principal. A antiga coluna única ETIOLOGIA_NORMALIZADA foi substituída por duas variáveis independentes: CLASSIFICACAO_FINAL_NORMALIZADA, derivada de CLASSI_FIN, e ETIOLOGIA_DETALHADA, derivada apenas das flags laboratoriais. O repository, a API, o relatório de qualidade e a documentação foram migrados para o novo modelo, preservando o contrato público do endpoint /api/v1/etiologia.

Validação. Ao final, a suíte completa executou 97 testes com sucesso, restando apenas um warning de depreciação externo do stack Starlette/httpx, sem falha funcional no projeto.

Item	Resultado
Branch de implementação	feature/etiology-normalization
Branch final	main
Tipo de merge	Fast-forward
Testes finais	97 passed
Principais arquivos de produção alterados	etiology.py, ingest.py, repository.py, quality.py
Principais testes alterados	test_etiology.py, test_ingest.py, test_repository.py, test_api.py, test_quality.py

2. Contexto e problema identificado

O pipeline original produzia uma única coluna analítica, ETIOLOGIA_NORMALIZADA, combinando informações de natureza diferente: a classificação final registrada em CLASSI_FIN e os resultados de campos laboratoriais como PCR_SARS2, PCR_FLUAS, PCR_FLUBS e PCR_VSR.

Esse desenho gerava risco metodológico porque uma classificação clínica/epidemiológica final podia ser usada como se fosse confirmação laboratorial. Um exemplo crítico era CLASSI_FIN=5, que fazia o registro ser categorizado como COVID-19 mesmo quando não existia PCR_SARS2 positivo.

```
# Lógica anterior (resumo)
if final_classification == 5 or _is_positive(row, "PCR_SARS2"):
    return "COVID-19"
```

A revisão estabeleceu que classificação final e etiologia laboratorial devem permanecer independentes, inclusive quando houver conflito entre elas. Essa decisão também reduz risco de vazamento de informação em modelos preditivos futuros, pois evita transformar desfechos/classificações posteriores em variáveis de entrada sem controle metodológico.

3. Decisões metodológicas adotadas

3.1 Classificação final normalizada

A coluna CLASSIFICACAO_FINAL_NORMALIZADA passou a depender exclusivamente de CLASSI_FIN:

CLASSI_FIN	CLASSIFICACAO_FINAL_NORMALIZADA
1	INFLUENZA
2	OUTRO_VIRUS_RESPIRATORIO
3	OUTRO_AGENTE_ETIOLOGICO
4	NAO_ESPECIFICADO
5	COVID-19
ausente	AUSENTE
inesperado (ex.: 9, 99)	OUTRO

Valores inesperados não são reinterpretados como “ignorado” sem evidência documental. O valor 9, por exemplo, é tratado como OUTRO até que uma documentação oficial específica justifique outra codificação.

3.2 Etiologia detalhada

A coluna ETIOLOGIA_DETALHADA passou a depender exclusivamente de flags laboratoriais positivas. A prioridade determinística usada na versão atual é:

Campo laboratorial positivo	ETIOLOGIA_DETALHADA
PCR_SARS2	SARS-CoV-2
PCR_FLUAS	Influenza A
PCR_FLUBS	Influenza B
PCR_VSR	VSR
PCR_ADENO	Adenovirus
PCR_PARA1	Parainfluenza 1
PCR_PARA2	Parainfluenza 2
PCR_PARA3	Parainfluenza 3
PCR_PARA4	Parainfluenza 4
PCR_METAP	Metapneumovirus
PCR_BOCA	Bocavirus
PCR_RINO	Rinovirus

Quando nenhum campo configurado está positivo, o valor é NAO_IDENTIFICADA. As flags originais são preservadas para possibilitar análise de coinfeções/co-deteções em versões futuras.

3.3 Regra central de independência

Exemplo:

CLASSI_FIN = 4

PCR_SARS2 = 1

CLASSIFICACAO_FINAL_NORMALIZADA = NAO_ESPECIFICADO

ETIOLOGIA_DETALHADA = SARS-CoV-2

O pipeline não “corrige” silenciosamente um campo com base no outro. Eventuais divergências permanecem observáveis e auditáveis.

3.4 Compatibilidade histórica 2019–2026

Foi mantido um único pipeline para todo o período 2019–2026. Diferenças de schema são tratadas como disponibilidade de colunas, e não como regras especiais por ano. Essa decisão é importante porque os arquivos históricos não possuem necessariamente os mesmos campos laboratoriais das versões mais recentes.

- Coluna inexistente no arquivo de origem não é criada artificialmente como resultado negativo.
- Valor ausente não é interpretado como resultado positivo.
- As colunas originais presentes na fonte são preservadas.
- Ausência de PCR_SARS2 em um schema histórico significa “campo não disponível”, e não “PCR SARS-CoV-2 negativo”.

4. Implementação realizada — Tasks 1 a 8

Task 1 — Classificação final oficial

Criação de `normalize_final_classification()` e do mapa de CLASSI_FIN. Testes cobriram valores 1–5, ausentes e inesperados.

Task 2 — Etiologia laboratorial detalhada

Criação de `normalize_detailed_etiology()` e `add_etiology_columns()`, com mapeamento explícito de vírus e manutenção temporária das funções antigas para migração segura.

Task 3 — Integração no ingest

O pipeline de transformação passou a chamar `add_etiology_columns()`. As funções legadas foram removidas e testes confirmaram preservação das colunas de origem.

Task 4 — Repository/DuckDB

Filtros e agregações migraram de ETIOLOGIA_NORMALIZADA para ETIOLOGIA_DETALHADA. O contrato público continuou usando o nome `etiologia`.

Task 5 — Compatibilidade da API

O endpoint `/api/v1/etiologia` permaneceu estável. Teste específico passou a validar que o filtro etiologia chega corretamente ao service e que rótulos como SARS-CoV-2 são devolvidos sem renomear o contrato externo.

Task 6 — Schemas históricos

Foram adicionados testes com schema 2019 sem campos COVID e com ausência de classificação/laboratório, confirmando tolerância a colunas inexistentes.

Task 7 — README

Documentação metodológica incorporada ao README, incluindo as duas colunas, a regra de independência e a compatibilidade histórica.

Task 8 — Verificação final

Busca por referências legadas em `src/tests`, correção do relatório de qualidade e execução da suíte completa antes do merge.

5. Exemplos de antes e depois

5.1 Estrutura das colunas

Situação	Antes	Depois
CLASSI_FIN=5, sem PCR_SARS2 positivo	ETIOLOGIA_NORMALIZADA = COVID-19	CLASSIFICACAO_FINAL_NORMALIZADA = COVID-19; ETIOLOGIA_DETALHADA = NAO_IDENTIFICADA
CLASSI_FIN=4 e PCR_SARS2=1	ETIOLOGIA_NORMALIZADA = COVID-19	NAO_ESPECIFICADO + SARS-CoV-2, preservados separadamente
Schema histórico sem PCR_SARS2	Campo inexistente podia ser confundido com ausência de positividade	Campo permanece inexistente; ETIOLOGIA_DETALHADA é calculada sem fabricar PCR_SARS2

5.2 Implementação central

```
FINAL_CLASSIFICATION_MAP = {
    1: "INFLUENZA",
    2: "OUTRO_VIRUS_RESPIRATORIO",
    3: "OUTRO_AGENTE_ETIOLOGICO",
    4: "NAO_ESPECIFICADO",
    5: "COVID-19",
}

def normalize_final_classification(value: object) -> str:
    if pd.isna(value):
        return "AUSENTE"
    return FINAL_CLASSIFICATION_MAP.get(value, "OUTRO")
```

```
def normalize_detailed_etiology(row: pd.Series) -> str:
    for field, label in LAB_ETIOLOGY_FIELDS:
        if _is_positive(row, field):
            return label
    return "NAO_IDENTIFICADA"
```

6. Estratégia de testes e validação

A implementação foi conduzida em ciclos RED → GREEN, adicionando testes antes ou durante cada migração e executando verificações específicas após cada etapa. Os principais grupos de teste cobriram:

- normalização de CLASSI_FIN;
- etiologia laboratorial para SARS-CoV-2, Influenza A/B, VSR e demais vírus;
- preservação de colunas originais;
- integração do ingest;
- agregação e filtros no repository;
- contrato público da API;
- schemas históricos;
- relatório de qualidade.

No encerramento, a suíte completa apresentou:

```
97 passed, 1 warning
```

O warning registrado é uma mensagem de depreciação do Starlette TestClient relacionada ao httpx e não representa falha funcional nos testes do projeto.

7. Fluxo Git e integração

- Desenvolvimento realizado na branch feature/etiology-normalization.
- Mudanças divididas em commits temáticos de documentação, normalização, ingest, repository, API, schemas históricos e quality report.
- Após a verificação final, a branch foi integrada na main por fast-forward.
- A branch de feature foi removida localmente após o merge e a main foi publicada no origin.

```
git checkout main
git pull
git merge feature/etiology-normalization
python -m pytest -v
git branch -d feature/etiology-normalization
git push origin main
```

8. Implicações para análise epidemiológica e Machine Learning

A separação conceitual melhora a qualidade analítica da base e é especialmente importante para a próxima fase de seleção de características e modelagem. Para Machine Learning, recomenda-se manter a distinção entre variáveis disponíveis no momento da predição e informações registradas posteriormente no curso do caso.

- Evitar usar CLASSI_FIN como preditor em modelos cujo objetivo seja antecipar desfecho ou diagnóstico, quando essa classificação só estiver disponível depois do momento clínico de interesse.
- Tratar explicitamente valores ausentes, ignorados e colunas inexistentes; não convertê-los indiscriminadamente em zero.
- Preservar as flags laboratoriais originais para possíveis representações multilabel e estudo de co-detecção.
- Documentar a disponibilidade de cada variável por ano antes do treinamento de modelos conjuntos 2019–2026.
- Realizar análise de leakage temporal e de informação antes da definição do conjunto final de features.

9. Limitações e pontos de atenção

- A ETIOLOGIA_DETALHADA atual escolhe a primeira flag positiva em uma ordem determinística; coinfeções ainda não são representadas como multilabel.
- O schema pode evoluir ao longo dos anos; novos campos laboratoriais devem ser incorporados de forma explícita e testada.
- A documentação oficial disponível para o período recente deve ser revisitada antes de reprocessamentos científicos definitivos, especialmente quando houver atualização de dicionário de dados.
- O relatório registra a lógica implementada; não substitui validação epidemiológica por especialista de domínio quando a análise for usada para publicação científica.

10. Arquivos principais modificados

Arquivo	Papel na mudança
src/srag_api/data/etiology.py	Normalização da classificação final e etiologia detalhada.
src/srag_api/data/ingest.py	Integração das novas colunas no pipeline.
src/srag_api/data/repository.py	Consulta/filtro/agregação por ETIOLOGIA_DETALHADA.
src/srag_api/data/quality.py	Contagem de etiologia não identificada usando a nova coluna.
tests/unit/test_etiology.py	Testes unitários da lógica etiológica.
tests/unit/test_ingest.py	Integração e compatibilidade histórica.
tests/integration/test_repository.py	Distribuição etiológica no DuckDB.
tests/integration/test_api.py	Preservação do contrato público da API.
tests/unit/test_quality.py	Validação do relatório de qualidade.
README.md	Documentação metodológica da solução.

11. Conclusão

A revisão corrigiu um problema metodológico relevante: a mistura entre classificação final e evidência laboratorial. O novo desenho mantém as duas dimensões independentes, preserva as colunas originais, tolera diferenças históricas de schema e mantém compatibilidade da API existente. A implementação foi integrada à main após validação completa com 97 testes passando.

Com essa base consolidada, o projeto está em melhor condição para avançar para a etapa de análise de literatura, seleção de características e experimentos de Machine Learning sobre os dados de SRAG.

12. Referências e materiais do projeto

- Ministério da Saúde / Dados Abertos. SRAG 2019 a 2026 — conjunto de dados SIVEP-Gripe.
- SIVEP-Gripe — ficha de investigação e dicionário de dados utilizados na revisão metodológica.
- Repositório GitHub: GT09PetSaudeDigital/grupo-srag.
- Documento de design: docs/superpowers/specs/2026-08-14-srag-etiology-normalization-design.md.
- Plano de implementação: docs/superpowers/plans/2026-08-14-srag-etiology-normalization-implementation-plan.md.

Apêndice A — Linha do tempo resumida da implementação

1. Auditoria da lógica antiga de etiologia e comparação com a codificação oficial de CLASSI_FIN.
2. Aprovação do desenho com duas colunas independentes.
3. Criação do documento de design e do plano de implementação.
4. Implementação e testes das Tasks 1–3 (normalização e ingest).
5. Migração do repository e atualização da API (Tasks 4–5).
6. Proteções para schemas históricos e documentação (Tasks 6–7).
7. Busca final por referências legadas, ajuste do quality report e suíte completa (Task 8).
8. Merge fast-forward na main, remoção da branch de feature e push para origin/main.