


# Explicação dos Gráficos - Análise SRAG (Paraná)


Base de dados: SIVEP-Gripe / Ministério da Saúde, [dadosabertos.saude.gov.br](https://dadosabertos.saude.gov.br).

## 1. Casos de SRAG por mês, Brasil x Paraná




Mostra quantos casos de SRAG foram registrados a cada mês, comparando o Brasil (linha verde) com o Paraná (linha laranja). Há um pico forte em meados de 2025 (junho/julho), tanto no Brasil quanto no PR, seguido de queda constante até o início de 2026, padrão típico de doenças respiratórias, que aumentam no inverno. O Brasil tem uma escala bem maior, mas as duas linhas sobem e descem juntas, mostrando que o Paraná segue a mesma tendência sazonal do país.

## 2. Distribuição de idade dos casos (Paraná)




Histograma das idades dos casos de SRAG no Paraná. Há dois grupos claros: um pico alto entre 0 e 5 anos (crianças pequenas, muito afetadas por vírus respiratórios) e um segundo aumento mais suave entre 60 e 85 anos (idosos, grupo de risco). Entre 20 e 50 anos os casos são raros. Esse formato bimodal é esperado nesse tipo de doença, já que crianças pequenas e idosos são os grupos mais vulneráveis.

## 3. Casos por sexo (Paraná)




Comparação entre o número de casos em mulheres (F) e homens (M). No Paraná os dois grupos ficaram praticamente empatados, indicando que o sexo isoladamente não é um fator relevante de risco para contrair SRAG.

#### 4. Evolução dos casos: cura x óbito (Paraná)




Mostra o desfecho final dos casos notificados. A grande maioria evolui para cura, enquanto uma parcela bem menor termina em óbito. A letalidade proporcional é baixa, mesmo com o número alto de notificações, mas os óbitos ainda formam uma base relevante para os modelos de Machine Learning tentarem prever quem tem mais risco.

#### 5. Taxa de internação em UTI por faixa etária (Paraná)




Percentual de cada faixa etária que precisou de UTI. Crianças de 0 a 12 anos têm a menor taxa (cerca de 19%), que sobe até o pico nas faixas de 46-60 e 61-75 anos (cerca de 32-33%). Na faixa 76+ a taxa cai um pouco, possivelmente porque pacientes muito idosos evoluem mais rápido para óbito sem passar por UTI. No geral, confirma que meia-idade e idosos são o grupo com maior necessidade de terapia intensiva.

## 6. Comorbidades mais comuns entre os casos (Paraná)



Percentual de casos com cada doença pré-existente registrada na ficha de notificação. Cardiopatia aparece bem à frente das outras, presente em quase 20% dos casos, seguida de diabetes (cerca de 11%). Doenças pulmonares, asma, problemas neurológicos, obesidade, doença renal e hepática aparecem em proporções bem menores. Cardiopatia e diabetes são, portanto, as comorbidades que mais acompanham os casos graves de SRAG no Paraná.

## 7. Municípios do Paraná com mais notificações



Ranking dos 15 municípios com mais casos notificados. Curitiba aparece muito à frente (mais de 6.000 casos), esperado por ser a capital e a cidade mais populosa, seguida de Londrina, Cascavel e Toledo. O

gráfico reflete principalmente o tamanho da população de cada cidade, não necessariamente a gravidade da doença ali; para comparar de forma mais justa seria preciso calcular a taxa por habitante.

## Machine Learning: Previsão de Óbito

Três algoritmos (Regressão Logística, Random Forest e Gradient Boosting) foram treinados para prever, a partir de idade, sexo, sintomas, comorbidades e vacinação, se um paciente do Paraná evoluiria para óbito ou cura. Os dados foram divididos em treino (75%) e teste (25%), e os modelos são avaliados apenas nos casos de teste, que não viram durante o treino.


### Tabela comparativa dos modelos (previsão de óbito)

| Modelo              | Acurácia | Precisão | Recall | F1    | AUC   |
|---------------------|----------|----------|--------|-------|-------|
| Regressão Logística | 69,9%    | 16,5%    | 79,2%  | 0,274 | 0,810 |
| Random Forest       | 71,7%    | 16,9%    | 75,4%  | 0,276 | 0,808 |
| Gradient Boosting   | 92,7%    | 32,4%    | 2,1%   | 0,039 | 0,812 |

Acurácia é o percentual total de acertos (métrica menos importante aqui, pois óbitos são raros e um modelo que só chutasse "cura" já acertaria quase sempre). Precisão é, dentre os casos marcados como óbito, quantos realmente eram. Recall é, dentre todos os óbitos reais, quantos o modelo identificou. F1 é a média entre precisão e recall. AUC mede a capacidade geral de separar quem vai a óbito de quem não vai (0,5 é chute aleatório, 1,0 é perfeito).


Os três modelos têm AUC parecido, em torno de 0,81, ou seja, capacidade semelhante de diferenciar os grupos de risco. O Gradient Boosting tem recall muito baixo (2,1%): quase não avisa quando alguém vai a óbito, embora acerte bastante quando aponta. A Regressão Logística e o Random Forest têm recall bem mais alto (75-79%), identificando a maioria dos óbitos reais, ao custo de mais falsos alarmes. Em saúde pública costuma valer mais um modelo com recall alto do que um que deixa passar muitos óbitos, então esses dois parecem mais úteis aqui, mesmo com acurácia total menor.

## Curva ROC (previsão de óbito)



Mostra o equilíbrio entre acertar os óbitos e gerar alarmes falsos, em diferentes níveis de sensibilidade do modelo; quanto mais a curva sobe perto do canto superior esquerdo, melhor. As três curvas praticamente se sobrepõem, confirmando o AUC semelhante: os modelos diferem mais no ponto de corte escolhido para decidir óbito ou não, e menos na qualidade da informação aprendida.


## Importância das variáveis, Random Forest (óbito)



Mostra quais variáveis mais pesaram na decisão do modelo. A idade é disparadamente a mais importante, respondendo por quase metade do peso total. Em seguida vêm cardiopatia, vacinação contra covid, saturação de oxigênio e dispneia. Isso bate com o esperado clinicamente: pacientes mais velhos, cardiopatas e com sinais de insuficiência respiratória são os de maior risco.

## Matrizes de confusão (previsão de óbito)

Mostram, em números, os acertos e erros de cada modelo: linha é o que realmente aconteceu, coluna é o que o modelo previu.




**4741 (canto superior esquerdo)** → paciente não foi a óbito, e o modelo acertou (previu "não"). Isso é um **acerto** (verdadeiro negativo).


**2113 (canto superior direito)** → paciente não foi a óbito, mas o modelo previu que ia morrer. Isso é um **falso alarme** (falso positivo).

**110 (canto inferior esquerdo)** → paciente foi a óbito, mas o modelo previu que ele ia sobreviver. Esse é o **erro mais grave**: o modelo "deixou passar" um óbito real (falso negativo).

**419 (canto inferior direito)** → paciente foi a óbito, e o modelo acertou a previsão. **Acerto** (verdadeiro positivo).







Confirmam o que a tabela já mostrava: Regressão Logística e Random Forest acertam a maior parte dos óbitos reais, mas também classificam bastante gente que sobreviveu como se fosse ir a óbito. O Gradient Boosting quase não aponta óbito para ninguém, por isso erra pouco entre quem sobreviveu, mas deixa passar praticamente todos os óbitos reais.

## Machine Learning: Previsão de Internação em UTI


Mesmo processo, agora prevendo se o paciente precisaria de internação em UTI, com as mesmas variáveis de entrada.

**Tabela comparativa dos modelos (previsão de UTI)**

| Modelo              | Acurácia | Precisão | Recall | F1    | AUC   |
|---------------------|----------|----------|--------|-------|-------|
| Regressão Logística | 62,1%    | 34,4%    | 58,8%  | 0,434 | 0,659 |
| Random Forest       | 64,0%    | 36,3%    | 60,5%  | 0,454 | 0,680 |
| Gradient Boosting   | 76,1%    | 60,1%    | 9,4%   | 0,162 | 0,683 |


O padrão entre os modelos é parecido com o da previsão de óbito, mas o desempenho geral é mais fraco (AUC entre 0,66 e 0,68, contra 0,81 para óbito). Isso faz sentido: internar em UTI depende de fatores clínicos como disponibilidade de leito e protocolo do hospital, que não estão na ficha de notificação. Ainda assim, os modelos captam um sinal real, acertando bem mais que um chute aleatório.

### Curva ROC (previsão de UTI)




Random Forest e Gradient Boosting ficam levemente acima da Regressão Logística na maior parte do gráfico, indicando que os modelos baseados em árvores captam um pouco melhor os padrões dos dados para esse problema.



### Importância das variáveis, Random Forest (UTI)



A idade aparece em primeiro lugar, mas com peso proporcionalmente menor que no caso do óbito. Tosse, saturação de oxigênio e escolaridade vêm em seguida. Tosse e saturação fazem sentido clínico direto; já a escolaridade com peso alto provavelmente reflete fatores socioeconômicos indiretos, como acesso a diagnóstico e tratamento mais cedo, e não uma relação de causa direta.

### Matrizes de confusão (previsão de UTI)





Regressão Logística e Random Forest identificam mais casos reais de UTI, enquanto o Gradient Boosting é mais conservador e deixa passar mais casos reais sem sinalizar, apesar da maior acurácia geral.